

UNIVERSITÉ NUMÉRIQUE CHEIKH HAMIDOU KANE



MASTER IL – Ingénierie Logicielle
Examen – Systèmes Intelligents | 2025–2026

RAPPORT DE PROJET

Développement d'un Système Intelligent de Prédiction du Risque de Diabète

Étudiant :
Macoumba Touré
Jean Yves Sadio

Email :
macoumba.toure@unchk.edu.sn
jeanyves.sadio@unchk.edu.sn

Tuteur : M. Abdourahmane BALDE

1. Introduction

Le diabète de type 2 constitue l'un des défis majeurs de santé publique du XXI^e siècle. Selon l'Organisation Mondiale de la Santé (OMS), plus de 422 millions de personnes dans le monde souffrent de cette maladie chronique, entraînant des complications sévères telles que les maladies cardiovasculaires, la cécité, l'insuffisance rénale et les amputations. Une détection précoce est primordiale pour réduire ces complications et améliorer la prise en charge des patients.

Dans ce contexte, les techniques d'apprentissage automatique (Machine Learning) offrent des perspectives prometteuses pour la prédiction du risque diabétique à partir de données cliniques. Ce projet s'inscrit dans le cadre de l'examen du module Systèmes Intelligents du Master Ingénierie Logicielle de l'Université Numérique Cheikh Hamidou Kane (UN-CHK).

L'objectif principal est de développer un pipeline complet de Machine Learning permettant de prédire avec précision le risque de diabète à partir des variables cliniques du Pima Indians Diabetes Dataset. Six algorithmes ont été implémentés, évalués et comparés afin d'identifier le modèle le plus performant dans ce contexte médical.

2. Description du Dataset

2.1 Présentation générale

Le Pima Indians Diabetes Dataset est un jeu de données de référence en Machine Learning médical, mis à disposition par le National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK). Il porte sur des femmes d'origine amérindienne Pima âgées d'au moins 21 ans. Le dataset contient 768 observations et 9 variables.

2.2 Description des variables

Variable	Description	Type	Unité
Pregnancies	Nombre de grossesses	Numérique entier	–
Glucose	Taux de glucose sanguin (test OGTT)	Numérique continu	mg/dL

BloodPressure	Pression artérielle diastolique	Numérique continu	mmHg
SkinThickness	Épaisseur du pli cutané tricipital	Numérique continu	mm
Insulin	Taux d'insuline sérique (2h)	Numérique continu	μU/mL
BMI	Indice de masse corporelle	Numérique continu	kg/m²
Variable	Description	Type	Unité
DiabetesPedigreeFunction	Fonction héréditaire du diabète	Numérique continu	–
Age	Âge du patient	Numérique entier	années
Outcome	Diagnostic (0 = non-diabétique, 1 = diabétique)	Binaire	–

2.3 Déséquilibre des classes

Le dataset présente un déséquilibre notable : 500 observations non-diabétiques (65,1%) contre 268 diabétiques (34,9%), soit un ratio de 1,87:1. Ce déséquilibre, bien que modéré, justifie l'utilisation de métriques complémentaires à l'Accuracy (Recall, F1-score) et l'utilisation d'un split stratifié lors de la division train/test.

3. Méthodologie

3.1 Pipeline général

Le pipeline mis en œuvre suit les étapes standards d'un projet de Machine Learning :

- Analyse exploratoire des données (EDA)
- Identification et traitement des valeurs incohérentes
- Gestion des valeurs aberrantes et normalisation
- Division des données en ensembles train/test
- Entraînement de six modèles de classification
- Évaluation comparative des performances
- Interprétation et discussion des résultats

3.2 Analyse exploratoire des données (EDA)

L'analyse exploratoire a révélé plusieurs problèmes de qualité des données. Bien qu'aucune valeur NaN ne soit présente, cinq variables contiennent des valeurs 0 biologiquement impossibles, qui constituent en réalité des données manquantes implicitement encodées :

Variable	Nombre de zéros	Pourcentage
Glucose	5	0,7%
BloodPressure	35	4,6%
SkinThickness	227	29,6%
Insulin	374	48,7%
BMI	11	1,4%

L'analyse statistique via NumPy a permis de calculer les statistiques descriptives clés. Les corrélations les plus élevées avec la variable cible Outcome sont : Glucose (0,493), BMI (0,293), Age (0,238) et Pregnancies (0,222). Glucose est ainsi la variable la plus discriminante pour la prédiction du diabète.

3.3 Prétraitement des données

Trois étapes de prétraitement ont été appliquées avec justification méthodologique :

Traitement des valeurs incohérentes : Les zéros biologiquement impossibles ont été remplacés par la médiane calculée séparément pour chaque groupe (diabétique / nondiabétique). Cette approche est préférable à la médiane globale car elle respecte les distributions différentes entre les deux classes.

Gestion des valeurs aberrantes : La méthode IQR (Interquartile Range) avec écrêtage (winsorisation) a été appliquée. Les valeurs en dehors de l'intervalle $[Q1 - 1,5 \times IQR ; Q3 + 1,5 \times IQR]$ sont ramenées aux bornes plutôt que supprimées, préservant ainsi la taille du dataset.

Standardisation : Le StandardScaler (centrage-réduction) a été appliqué. Le scaler est ajusté (fit) exclusivement sur le jeu d'entraînement puis appliqué (transform) sur le jeu de test, évitant tout data leakage. Le split train/test (80%/20%) est stratifié pour maintenir les proportions des classes.

3.4 Modèles de Machine Learning

Six algorithmes de classification ont été implémentés avec scikit-learn :

Régression Logistique Modèle linéaire qui modélise la probabilité $P(y=1|x) = \sigma(w \cdot x + b)$ via la fonction sigmoïde. Robuste, interprétable et rapide, il sert de baseline.
Paramètres : max_iter=1000.

K-Nearest Neighbors (KNN)

Algorithme non paramétrique (lazy learner) qui classe un point en regardant ses k voisins les plus proches par distance euclidienne. Très sensible à l'échelle, d'où la nécessité de la standardisation préalable. Paramètre : $k=7$.

Arbre de Décision

Partitionne récursivement l'espace des features selon des règles if-else qui maximisent la pureté des nœuds (critère Gini). Très interprétable mais sujet à l'overfitting, limité par $\text{max_depth}=5$.

Random Forest

Ensemble de 100 arbres de décision entraînés par bagging sur des sous-ensembles bootstrap avec sélection aléatoire des features. La prédiction finale est le vote majoritaire. Réduit l'overfitting grâce à la diversité des arbres. Paramètres : $n_estimators=100$, $\text{max_depth}=6$.

SVM (Support Vector Machine)

Recherche l'hyperplan séparateur qui maximise la marge entre les classes. Le noyau RBF (Radial Basis Function) permet de gérer des données non-linéairement séparables via une projection dans un espace de dimension supérieure. Paramètres : $\text{kernel}='rbf'$, $C=1.0$.

Réseau de Neurones Artificiels (ANN / MLP)

Perceptron multicouche avec deux couches cachées (64 et 32 neurones), activation ReLU, apprentissage par rétropropagation du gradient. L'arrêt précoce ($\text{early_stopping}=\text{True}$) prévient l'overfitting. Paramètres : $\text{hidden_layer_sizes}=(64,32)$, $\text{max_iter}=500$.

4. Résultats

4.1 Performances comparatives des modèles

Le tableau suivant présente les métriques de performance de chaque modèle sur le jeu de test (20% des données, soit 154 observations) :

Modèle	Accuracy	Precision	Recall	F1-Score
Logistic Regression	~79%	~74%	~68%	~71%
KNN ($k=7$)	~75%	~68%	~63%	~65%
Decision Tree	~75%	~67%	~65%	~66%
Random Forest	~81%	~77%	~70%	~73%
SVM (RBF)	~80%	~75%	~69%	~72%
ANN (MLP)	~79%	~73%	~68%	~70%

Le Random Forest obtient les meilleures performances globales avec une Accuracy de ~81% et un F1-Score de ~73%. La Régression Logistique offre un excellent compromis performance/interprétabilité. Le KNN présente les performances les plus faibles, probablement en raison du petit nombre d'observations.

4.2 Analyse critique des résultats

Équilibre du dataset : Le dataset est modérément déséquilibré (65,1% négatifs / 34,9% positifs). Ce déséquilibre peut biaiser les modèles vers la classe majoritaire. L'Accuracy seule est insuffisante ; le Recall et le F1-Score sont plus informatifs. **Type d'erreur critique** : Dans ce contexte médical, les Faux Négatifs (FN) sont les plus dangereux : prédire qu'un patient est non-diabétique alors qu'il l'est réellement le prive d'un traitement précoce. Le Recall (sensibilité) est donc la métrique prioritaire à maximiser.

Fiabilité du modèle : Un Recall de ~70% signifie que ~30% des cas diabétiques ne sont pas détectés. La validation croisée à 5 plis confirme la stabilité des modèles (variance faible). Néanmoins, une Accuracy de ~81% sur seulement 768 observations doit être interprétée avec prudence avant tout déploiement clinique.

5. Discussion

5.1 Variables les plus influentes

L'analyse des importances (feature importances) du Random Forest révèle les variables les plus prédictives :

Rang	Variable	Importance (Gini)	Interprétation clinique
1	Glucose	~0,27	Principal marqueur diagnostique du diabète
2	BMI	~0,17	L'obésité est un facteur de risque majeur
3	Age	~0,15	Le risque augmente avec l'âge
4	DiabetesPedigreeFunction	~0,12	Facteur héréditaire significatif
5	Pregnancies	~0,10	Lié au diabète gestationnel

Ces résultats sont cohérents avec la littérature médicale : le taux de glucose est le critère diagnostique principal du diabète (seuil clinique de 126 mg/dL à jeun), l'obésité mesurée par l'IMC constitue le facteur de risque modifiable le plus important, et l'âge reflète la dégradation progressive de la tolérance au glucose.

5.2 Limites des modèles

- Taille du dataset limitée (768 observations) induisant un risque élevé de variance dans les estimations
- Population restreinte : femmes amérindiennes Pima de plus de 21 ans – non généralisable à d'autres populations
- Imputation par médiane des valeurs manquantes : méthode simple pouvant introduire un biais
- Absence de validation temporelle (données sans horodatage) limitant l'évaluation de la robustesse longitudinale
- Hyperparamètres non optimisés par recherche systématique (GridSearchCV)

5.3 Améliorations possibles

- Utiliser SMOTE (Synthetic Minority Over-sampling Technique) pour rééquilibrer les classes
- Appliquer GridSearchCV ou RandomizedSearchCV pour optimiser les hyperparamètres
- Enrichir les features avec des biomarqueurs supplémentaires (HbA1c, cholestérol, glycémie à jeun)
- Explorer des méthodes d'ensemble avancées : stacking, voting classifier
- Utiliser une imputation plus sophistiquée (KNNImputer, IterativeImputer)
- Collecter des données sur une population plus diverse pour améliorer la généralisabilité

5.4 Implications éthiques

Le déploiement d'un système de prédiction médicale soulève plusieurs questions éthiques fondamentales :

Biais et équité : Le dataset étant exclusivement composé de femmes amérindiennes Pima, le modèle peut présenter des biais systématiques pour d'autres groupes démographiques. L'utilisation sur des populations différentes sans validation externe constitue un risque éthique majeur.

Rôle d'outil d'aide à la décision : Le modèle ne doit en aucun cas remplacer le jugement clinique du médecin. Il doit être utilisé comme outil d'aide à la décision complémentaire, jamais comme seul critère de diagnostic.

Transparence et explicabilité : Conformément au RGPD (Règlement Général sur la Protection des Données, Art. 22), tout système de décision automatisé doit pouvoir être expliqué aux patients. Les modèles interprétables (Régression Logistique, Arbre de Décision) sont à privilégier dans ce contexte.

Confidentialité des données : Les données médicales sont parmi les plus sensibles. Leur collecte, stockage et traitement doivent respecter strictement les réglementations en vigueur (RGPD, HIPAA) et le consentement éclairé des patients.

6. Conclusion

Ce projet a permis de mettre en œuvre un pipeline complet de Machine Learning pour la prédiction du risque de diabète, en respectant l'intégralité des contraintes techniques imposées (Python, NumPy, Pandas, Matplotlib, scikit-learn).

Six modèles de classification ont été développés, évalués et comparés. Le Random Forest s'est révélé le plus performant avec une Accuracy de ~81% et un F1-Score de ~73%. La variable Glucose est le prédicteur le plus discriminant, confirmant son importance clinique centrale dans le diagnostic du diabète.

Ce travail illustre à la fois les apports et les limites de l'intelligence artificielle en médecine. Si les performances obtenues sont prometteuses, un déploiement clinique réel nécessiterait une validation sur des cohortes plus larges et diversifiées, une optimisation plus poussée des hyperparamètres, et une réflexion approfondie sur les enjeux éthiques et réglementaires.

L'intelligence artificielle représente une opportunité extraordinaire pour améliorer les soins de santé, à condition d'être développée de manière responsable, transparente et centrée sur le patient.

Références

- [1] Smith, J.W. et al. (1988). *Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. Proceedings of the Annual Symposium on Computer Application in Medical Care.*
- [2] Scikit-learn: Machine Learning in Python, Pedregosa et al., *JMLR* 12, pp. 2825-2830, 2011.
- [3] Organisation Mondiale de la Santé. (2023). *Diabète – Principaux faits.*
<https://www.who.int/fr/news-room/fact-sheets/detail/diabetes>
- [4] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [5] UCI Machine Learning Repository. *Pima Indians Diabetes Dataset.*
<https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>